



Python для анализа данных

Итоговый проект

Санкт-Петербург
12 марта 2026

Анализ взаимосвязи факторов образа жизни и академической успеваемости студентов

Овсянникова Майя Дмитриевна ББИ241с
mdovsyannikova@edu.hse.ru

Департамент бизнес-информатики и операционного менеджмента
Санкт-Петербургская школа экономики и менеджмента



Цель работы:

Исследовать различные факторы жизни и учебы студентов и их взаимосвязь: успеваемость, пол, аспекты образа жизни.

Датасет:

<https://www.kaggle.com/datasets/charlottebennett1234/lifestyle-factors-and-their-impact-on-students/data>



Описание набора данных

Набор данных содержит информацию об образе жизни и успеваемости **2000** студентов университета. Данные собраны за академический год с помощью Google Forms. Датасет имеет открытую лицензию.

Таблица 1 — Атрибуты набора данных

Атрибут	Значение	Тип переменной
Student_ID	уникальный идентификатор	Категориальная номинальная
Gender	пол	Категориальная номинальная
Stress_Level	уровень стресса	Категориальная порядковая
Grades	успеваемость	Метрическая интервальная
Study_Hours_Per_Day	среднее количество учебных часов в день	Метрическая абсолютная
Extracurricular_Hours_Per_Day	среднее количество часов внеучебной активности в день	Метрическая абсолютная
Sleep_Hours_Per_Day	среднее количество часов сна в день	Метрическая абсолютная
Social_Hours_Per_Day	среднее количество часов на общение в день	Метрическая абсолютная
Physical_Activity_Hours_Per_Day	среднее количество часов физической активности в день	Метрическая абсолютная



Описание набора данных

Инструментами Python удобно разделить атрибуты на метрические и категориальные методами:

```
df.select_dtypes(include=['int64', 'float64']).columns.tolist()
df.select_dtypes(include=['object', 'category']).columns.tolist()
```

Но нужно быть внимательными с полями «ID» и аналогичными.

```
metric_columns = df.select_dtypes(include=['int64', 'float64']).columns.tolist()
metric_columns.remove('Student_ID')
print(f"metric_columns: {metric_columns}")

categorical_columns = df.select_dtypes(include=['object', 'category']).columns.tolist()
print(f"categorical_columns: {categorical_columns}")
```

[63]

```
... metric_columns: ['Study_Hours_Per_Day', 'Extracurricular_Hours_Per_Day', 'Sleep_Hours_Per_Day', 'Social_Hours_Per_Day', 'Physical_Activity_Hours_Per_Day', 'Grades']
categorical_columns: ['Stress_Level', 'Gender']
```

Рисунок 1 — Определение метрических и категориальных атрибутов



Описание набора данных

Атрибут **Grades** – успеваемость, представлена средним баллом (GPA).

min: 5.60
max: 10.00

mean: 7.79
median: 7.78
mode: 7.78





Рисунок 2 — Распределение оценок студентов (атрибут Grades)

Очистка от неправильных значений и выбросов

Пустые значения и дубликаты

```
[62]
print(f"Количество пропусков:\n{df.isnull().sum()}\n")
print(f"Количество дубликатов: {df.duplicated().sum()}")

...
Количество пропусков:
Student_ID          0
Study_Hours_Per_Day 0
Extracurricular_Hours_Per_Day 0
Sleep_Hours_Per_Day 0
Social_Hours_Per_Day 0
Physical_Activity_Hours_Per_Day 0
Stress_Level        0
Gender              0
Grades              0
dtype: int64

Количество дубликатов: 0
```

Рисунок 3 — Проверка на пустые значения и дубликаты

Датасет оказался очень хорошим и **не содержит в себе пустых значений, а также и дубликатов.**

При их наличии необходимо бы было, основываясь на более детальном анализе, решить, что с ними делать — удалить, заменить медианой, модой и прочие варианты.

Но нам повезло



Рисунок 4 — Цветочек



Очистка от неправильных значений и выбросов

Метрические переменные

```
df[metric_columns].describe().round(2)
```

	Study_Hours_Per_Day	Extracurricular_Hours_Per_Day	Sleep_Hours_Per_Day	Social_Hours_Per_Day	Physical_Activity_Hours_Per_Day	Grades
count	2000.00	2000.00	2000.00	2000.00	2000.00	2000.00
mean	7.48	1.99	7.50	2.70	4.33	7.79
std	1.42	1.16	1.46	1.69	2.51	0.75
min	5.00	0.00	5.00	0.00	0.00	5.60
25%	6.30	1.00	6.20	1.20	2.40	7.25
50%	7.40	2.00	7.50	2.60	4.10	7.78
75%	8.70	3.00	8.80	4.10	6.10	8.32
max	10.00	4.00	10.00	6.00	13.00	10.00

Рисунок 5 — Метод `.describe()` для метрических атрибутов

Метод `.describe()` показывает основные характеристики метрических атрибутов и мы видим, что они все лежат в разумных диапазонах своих значений (в том числе нет отрицательных).

Каких-то **аномальных неправильных значений не наблюдается**.

Но можно заметить потенциальный выброс: 13 часов `Physical_Activity_Hours_Per_Day` выглядит странно.

Очистка от неправильных значений и выбросов. Визуализация

Метрические переменные

Визуализация в виде ящиков с усами позволяет увидеть выбросы атрибутов.




Рисунок 6 — Ящики с усами для метрических атрибутов

Очистка от неправильных значений и выбросов

Метрические переменные. Очистка выбросов

```
for col in metric_columns:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR
    df = df[(df[col] >= lower_bound) & (df[col] <= upper_bound)]
```

Рисунок 7 — Очистка выбросов методом IQR

```
...
Выбросы до очистки
Study_Hours_Per_Day: 0 выбросов
Extracurricular_Hours_Per_Day: 0 выбросов
Sleep_Hours_Per_Day: 0 выбросов
Social_Hours_Per_Day: 0 выбросов
Physical_Activity_Hours_Per_Day: 5 выбросов
Grades: 4 выбросов

Размер df до очистки: 2000
Размер df после очистки: 1991

Повторная проверка: выбросы после очистки
Study_Hours_Per_Day: 0 выбросов
Extracurricular_Hours_Per_Day: 0 выбросов
Sleep_Hours_Per_Day: 0 выбросов
Social_Hours_Per_Day: 0 выбросов
Physical_Activity_Hours_Per_Day: 0 выбросов
Grades: 0 выбросов
```

Рисунок 8 — Результат удаления выбросов и повторная проверка

Методом межквартильного размаха определяем количество выбросов в каждом атрибуте.

Выбросы в `Physical_Activity_Hours_Per_Day` действительно выглядят как ошибки: количество часов занятий спортом в день от 11.7 до 13 не является реалистичным.

Строк с выбросами менее **0,5%** от размера датасета.

Очистка от неправильных значений и выбросов. Визуализация Категориальные переменные




Рисунок 9 — Круговые диаграммы для категориальных атрибутов

Визуализация круговой диаграммой и метод `.describe()` показывают, что в категориальных атрибутах **нет некорректных значений**.

Диаграммы показывают, что количество студентов обоих полов в выборке примерно равно, а также большая часть студентов имеют высокий уровень стресса.

```
df[categorical_columns].describe()
```

	Stress_Level	Gender
count	2000	2000
unique	3	2

Рисунок 10 — Часть результата выполнения метода `.describe()` для категориальных атрибутов

Проверка статистической гипотезы о равенстве средних

H_0 (нулевая гипотеза): Среднее количество часов сна в сутки у студентов мужского и женского пола одинаково

H_1 (альтернативная гипотеза): Среднее количество часов сна в сутки у студентов мужского и женского пола отличается

Для проверки гипотезы планируем использовать **независимый (двухвыборочный) t-тест**.

Критерии применимости t-теста:

- независимость данных (соблюдается) ✓
- нормальность распределения в каждой выборке (проверим) ✗
- равенство дисперсий (проверим) ✓




Рисунок 11 — Визуализация распределения часов сна в выборках

Проверка статистической гипотезы о равенстве средних

Тест Шапиро-Уилка показал, что гипотеза о нормальности распределения в выборках не может быть принята, то есть не может быть и применен t-тест для проверки исходной гипотезы.

Для ее проверки был выбран **bootstrap-тест**

Критерии применимости bootstrap-теста:

- независимость данных (соблюдается) ✓
- достаточный размер выборки (соблюдается) ✓
- выборка отражает генеральную совокупность (соблюдается) ✓
- отсутствие существенных выбросов (проверили) ✓

```
shapiro_male = stats.shapiro(male_sleep)
shapiro_female = stats.shapiro(female_sleep)

print(f"Male: тест Шапиро-Уилка, p_value = {shapiro_male.pvalue:.7f}")
print(f"Female: тест Шапиро-Уилка, p_value = {shapiro_female.pvalue:.7f}")

Male: тест Шапиро-Уилка, p_value = 0.0000000
Female: тест Шапиро-Уилка, p_value = 0.0000000
```

Рисунок 12 — Результат теста Шапиро-Уилка

```
# запуск bootstrap-теста
observed_diff, p_value, bootstrap_diffs, ci_lower, ci_upper = bootstrap_mean_test(male_sleep, female_sleep, n=10000)

print(f"Наблюдаемая разница средних Male -- Female: {observed_diff:.3f}")
print(f"Bootstrap p-value: {p_value:.3f}")

Наблюдаемая разница средних Male -- Female: 0.050
Bootstrap p-value: 0.448
```

Рисунок 13 — Результат bootstrap теста

По результатам теста $p_{value} = 0.448 > \alpha = 0.05$ — значительно больше уровня статистической значимости α , а значит мы **не отвергаем** нулевую гипотезу. То есть действительно:

Среднее количество часов сна в сутки у студентов мужского и женского пола одинаково.

Анализ взаимосвязей параметров

Метрические

Есть сильная положительная корреляция **0.73** между **Grades** и **Study_Hours_Per_Day**, это логично и можно интерпретировать как «чем больше часов в день студент учится, тем выше его оценки» (и наоборот).

Интересно, что при этом корреляция между **Sleep_Hours_Per_Day** и **Study_Hours_Per_Day** близка к 0; также с **Grades**.

Мне казалось, что по идее у таких параметров должна быть линейная положительная корреляция «чем больше спишь (без ухода в *inf* = 10+ часов), тем лучше оценки», но корреляции совсем нет.

Возможно тут более сложная квадратичная функция?

Предположение: парабола ветвями вниз – «крайности» это плохие оценки




Рисунок 14 — Матрица корреляций

Анализ взаимосвязей параметров

Агрегация и группировка

```
df['Sleep_Hours_Rounded'] = df['Sleep_Hours_Per_Day'].round()
df['Study_Hours_Rounded'] = df['Study_Hours_Per_Day'].round()

grouped_data = df.groupby(['Sleep_Hours_Rounded', 'Study_Hours_Rounded']).agg({
    'Grades': ['mean', 'count'],
    'Student_ID': 'count'
}).round(2)
```

Рисунок 15 — Агрегация и группировка




Рисунок 17 — Линейный график (стресс)




Рисунок 16 — Линейный график

В каждой группе оценки практически не зависят от количества сна, разве что совсем малое количество сна заметно их ухудшает.

Студенты со средним и слабым уровнем стресса спят не менее 6 целых часов.

А также никакой предполагаемой параболы в зависимости оценок и сна нет совсем.

Анализ взаимосвязей параметров

Категориальные

Для анализа взаимосвязи между двумя неметрическими переменными используется критерий χ^2 .

```

from scipy.stats import chi2_contingency

chi2, p, dof, expected = chi2_contingency(pd.crosstab(df['Stress_Level'], df['Gender']))
print(f"Хи-квадрат: {chi2:.3f}, p-value: {p:.5f}")

```

[286]

... Хи-квадрат: 0.709, p-value: 0.70154

Рисунок 18 — Критерий χ^2

$p_{value} = 0.7 > \alpha = 0.05$ — у нас нет оснований отвергнуть нулевую гипотезу H_0 критерия χ^2 о том, что переменные независимы. То есть **нет** статистически значимой **связи** между уровнем стресса и гендером, что логично.



Анализ взаимосвязей параметров

Метрические — Категориальные

Используем функции `ttest_ind` и `f_oneway` для проведение t-теста для 2х групп и ANOVA теста

Есть статистически значимая сильная связь между **Stress_Level1** и **Study_Hours_Per_Day**, **Sleep_Hours_Per_Day**, **Physical_Activity_Hours_Per_Day**, **Grades**

Gender же не влияет значимо ни на одну метрическую переменную

```
from scipy.stats import ttest_ind
from scipy.stats import f_oneway

for c_cl in categorical_columns:
    for m_cl in metric_columns:
        if df[c_cl].nunique() == 2: # t-test для 2 групп
            groups = [df[df[c_cl] == val][m_cl] for val in df[c_cl].unique()]
            t_stat, p_val = ttest_ind(groups[0], groups[1], nan_policy='omit')

            print(f"{c_cl} - {m_cl}: t_stat = {t_stat:.3f}, p-value = {p_val:.5f}")

        elif df[c_cl].nunique() > 2: # ANOVA для > 2 групп
            groups = [df[df[c_cl] == val][m_cl] for val in df[c_cl].unique()]
            f_stat, p_val = f_oneway(*groups)

            print(f"{c_cl} - {m_cl}: f_stat = {f_stat:.3f}, p-value = {p_val:.5f}")
```

Рисунок 19 — t-тест и ANOVA тест

Модель линейной регрессии




Рисунок 20 — Модель линейной регрессии

Модель линейной регрессии для прогнозирования оценок студентов на основе их образа жизни

Обучающая выборка

MSE: 0.249

RMSE: 0.499

MAE: 0.394

R2: 0.539

Тестовая выборка

MSE: 0.266

RMSE: 0.516

MAE: 0.418

R2: 0.538



Модель линейной регрессии

- **RMSE** (0.516) и **MAE** (0.418) показывают, что в среднем модель ошибается при предсказании оценки студента примерно на 0,5 балла.

Диапазон **Grades** в датасете составляет примерно от 6 до 9 баллов, ошибка в 0,5 балла является вполне приемлемой, **модель может довольно точно предсказать оценку.**

- **R²** (0.538) означает, что модель объясняет 53,8% вариации (дисперсии) оценок студентов.

То есть чуть более половины того, почему один студент учится лучше другого, можно объяснить теми факторами, которые мы включили в модель. Это довольно логично, например остальные факторы могли быть: мотивация, как-либо измеренные способности, первоначальный уровень подготовки и т.д.

- Наибольший положительный эффект на оценку оказывает количество часов учебы в день (**Study_Hours_Per_Day**).
Остальные факторы имеют небольшое отрицательное влияние.

	Признак	Коэффициент
0	Study_Hours_Per_Day	0.468834
4	Physical_Activity_Hours_Per_Day	-0.121963
2	Sleep_Hours_Per_Day	-0.089230
3	Social_Hours_Per_Day	-0.083233
1	Extracurricular_Hours_Per_Day	-0.083170
5	Gender_Encoded	-0.008521
6	Stress_Level_Encoded	-0.000831
Свободный член:		7.7832

Рисунок 21 — Коэффициенты модели

Модель кластеризации




Рисунок 22 — Выбор количества кластеров




Рисунок 23 — Визуализация кластеров

Выбрано оптимальное $k = 3$



Модель кластеризации

Таблица 2 — Сводка по кластерам

Кластер	Study_Hours_Per_Day	Extracurricular_Hours_Per_Day	Sleep_Hours_Per_Day	Social_Hours_Per_Day	Physical_Activity_Hours_Per_Day	Grades	Count
0	8.40	2.51	8.60	1.61	2.87	8.11	638
1	7.36	1.92	7.21	4.49	3.03	7.76	724
2	6.68	1.56	6.73	1.77	7.26	7.50	638




Рисунок 24 — Профили кластеров

Выделяются 3 характерные группы:

- «Отличники»
- Социально активные студенты
- Спортсмены



Цель работы:

Исследовать различные факторы жизни и учебы студентов и их взаимосвязь: успеваемость, пол, аспекты образа жизни.

Выводы:

Ключевой фактор успеваемости

При помощи статистических методов, и также при получении коэффициентов модели линейной регрессии подтверждена единственная сильная прямая взаимосвязь между **количеством часов учебы в день** и **средним баллом**.

А также проанализированы и визуализированы взаимосвязи других атрибутов.

Проверка гипотез

Статистически значимой связи между полом студента и количеством сна не обнаружено.

Гипотеза о влиянии сна на оценки также не подтвердилась — линейной или квадратичной зависимости не выявлено.

Модель линейной регрессии

Построенная модель линейной регрессии позволяет прогнозировать средний балл с приемлемой точностью (ошибка MAE ~0.42 балла) и объясняет 54% вариации оценок.

Профили студентов

Кластерный анализ выделил три характерных типа студентов: **«Отличники»**, **«Социально активные»** и **«Спортсмены»**.

Подводя итог,

В работе продемонстрировано использование различных методов для анализа данных в Python, построены множество разных визуализаций, использованы статистические инструменты, выполнена агрегация и группировка. Проведена предварительная подготовка данных, разведочный анализ и построены две ML модели, что позволило достичь поставленной цели — проанализировать ключевые взаимосвязи между образом жизни и успеваемостью студентов.

